

810100355

تمرین ML - سری 1

سازارستقی

(الف) ①

$$a \leq b \xrightarrow{(a>0)} a^2 \leq ab \xrightarrow{\sqrt{\cdot}} \sqrt{a^2} \leq \sqrt{ab} \rightarrow a \leq \sqrt{ab}$$

(ب)

$$P(\text{error}) = P(\text{mistake}) = \int_{R_1} \underbrace{P(x, c_2)}_{P(c_2|x)P(x)} dx + \int_{R_2} \underbrace{P(x, c_1)}_{P(c_1|x)P(x)} dx \quad (*)$$

در ناحیه مربوط به کلاس 1 (در R_1):

$$P(c_2|x) < P(c_1|x) \xrightarrow{\text{طبق بخش الف}} P(c_2|x) \leq \sqrt{P(c_2|x)P(c_1|x)}$$

همچنین در ناحیه R_2 داریم:

$$P(c_1|x) < P(c_2|x) \xrightarrow{\text{طبق بخش الف}} P(c_1|x) \leq \sqrt{P(c_1|x)P(c_2|x)}$$

آنچه داریم:

$$\int_{R_1} \underbrace{P(x, c_2)}_{P(c_2|x)P(x)} dx \leq \int_{R_1} \sqrt{P(c_2|x)P(c_1|x)} \cdot P(x) dx$$

$$\int_{R_2} \underbrace{P(x, c_1)}_{P(c_1|x)P(x)} dx \leq \int_{R_2} \sqrt{P(c_1|x)P(c_2|x)} \cdot P(x) dx$$

(*) $\rightarrow P(\text{error}) = P(\text{mistake}) \leq \int_{R_1} \sqrt{P(c_1|x)P(c_2|x)} \cdot P(x) dx +$

$$\int_{R_2} \sqrt{P(c_1|x)P(c_2|x)} \cdot P(x) dx = \int \sqrt{P(c_1|x)P(c_2|x)} \cdot P(x) dx$$

$$\int \sqrt{P(C_1|x)P(C_2|x)} p(x) dx = \int \sqrt{\frac{P(C_1|x) \cdot p(x)}{P(x, C_1)} \cdot \frac{P(C_2|x) \cdot p(x)}{P(x, C_2)}} dx$$

$$= \int \{P(x, C_1) \cdot P(x, C_2)\}^{\frac{1}{2}} dx \Rightarrow P(\text{mistake}) \leq \int \{P(x, C_1) \cdot P(x, C_2)\}^{\frac{1}{2}} dx$$

(2)

الف) **Recall**: کسری از داده های متعلق به کلاس هدف (positive) که توسط مدل ما به درستی پیش بینی شده اند.

$$\text{Recall} = \frac{TP}{TP + FN}$$

precision: کسری از داده ها که عضو کلاس هدف پیش بینی شده اند (positive) پیش بینی شده اند که واقعاً عضو کلاس هدف بوده اند. (از بین داده هایی که + پیش بینی شده اند هم کسری از آن ها واقعاً درست پیش بینی شده و عضو کلاس بوده اند)

$$\text{precision} = \frac{TP}{TP + FP}$$

accuracy: کسر داده هایی که به درستی پیش بینی شده اند. (به درستی تشخیص داده شده که عضو کلاس هستند یا عضو کلاس نیستند)

$$\text{Accuracy} = \frac{TN + TP}{TN + FN + TP + FP}$$

T: یعنی تشخیص درست

F: یعنی تشخیص (پیش بینی) اشتباه

P: عضو کلاس + تشخیص داده شده

N: عضو کلاس - تشخیص داده شده (در واقع تشخیص داده شده که عضو کلاس + نیست)

ب) ریسک تشخیص ندادن بیماری یک فرد بیمار بیشتر از ریسک تشخیص ندادن سلامتی یک فرد سالم است. اینکه بیماری یک فرد را بتوانیم تشخیص دهیم مسلماً خطر ناگهانی از این است که به یک فرد سالم بگویم بیمار است.

پس ما باید به دنبال معیاری باشیم که FN را کمینه کند و TP را بیشینه کند. همان تشخیص درست بیماری بوده و FN عدم تشخیص بیماری یک فرد بیمار می باشد.


با افزایش مقدار Recall، این اهداف محقق می شوند.

$$\text{Recall} = \frac{TP}{TP + FN}$$


ج) discriminability به معنی قابلیت تمایز دو توزیع (در اینجا به طور خاص توزیع می باشد).

هر چه فاصله میانگین دو توزیع از هم بیشتر بوده و واریانس آن ها کمتر باشد، توزیع ها از هم discriminable تر هستند و بیشتر قابل تمیز می باشند.

هر چه بیشتر باشد، دو کلاس راحت تر قابل تمیز هستند

$$\text{discriminability} = \frac{|\mu_2 - \mu_1|}{\frac{\sigma_1 + \sigma_2}{2}}$$


①



②

discriminability بین دو توزیع درست شکل
② بیشتر از شکل ① است

د) هدف از classification این است که برای هر داده ورودی unseen مدل X بتوانیم یک کلاس (همان label) assign کنیم. به تعبیری تشخیص دهیم این داده ی مدیر به چه کلاسی تعلق دارد.

روش های discriminative، مدل از احتمال شرطی $P(w|x)$ برای پیش بینی داده های unseen استفاده می کند. این روش ها برای بست آوردن احتمال، به طور مستقیم یک توزیع فرضی برای $P(w|x)$ در نظر می گیرند و سپس پارامترهای این توزیع را با کمک داده های train تخمین می زنند. برخی مدل های discriminative عبارتند از: SVMs، logistic Regression،


Forest، nearest neighbor، decision Trees & Random V.

روش های Generative، برای درست آوردن احتمال شرطی $P(y|x)$ ، احتمال Prior $P(y)$ و likelihood $P(x|y)$ را به کمک داده ی train تخمین می زنند و سپس

طبقه رابطنی Bayes ، احتمال posterior $P(Y|X)$ را محاسبه می کند.
برخی مدل های Generative عبارتند از: Naive Bayes ، Bayesian networks ، HMMs و ...

(ه) برای یک طبقه بند مطلوب ، سطح زیر نمودار ROC بیشتر خواهد بود ، به طوریکه در حالت ایده آل (طبقه بندی که همیشه همه داده ها را درست دسته بندی کند) سطح زیر نمودار ∞ خواهد گشت.

classifier هایی که منحنی آن ها به گوشه ی بالا سمت چپ نزدیک تر است ، عملکرد بهتری دارند.



3

$$P(x|w_2) \sim U(a, b) \quad , \quad P(x|w_1) \sim N(\mu, \sigma^2)$$

$$g(x) = g_1(x) - g_2(x) = P(w_1|x) - P(w_2|x) = P(x|w_1)P(w_1) - P(x|w_2)P(w_2)$$

$$\Rightarrow \text{if } g(x) \begin{cases} > 0 & \text{choose } w_1 \\ < 0 & \text{choose } w_2 \end{cases} \Rightarrow P(x|w_1)P(w_1) > P(x|w_2)P(w_2)$$

$$\Rightarrow \frac{P(x|w_1)}{P(x|w_2)} > \frac{P(w_2)}{P(w_1)} \Rightarrow$$

در این صورت w_1

ممکن است $P(x|w_2) = 0$

$$\text{decision} \begin{cases} w_1 ; & P(x|w_1) > \frac{P(w_2)}{P(w_1)} \times P(x|w_2) \\ w_2 ; & \text{otherwise} \end{cases}$$

در این صورت نباید خروج باشد پس می توانیم

• if $x \notin [a, b] \Rightarrow p(x|w_2) = 0 \xrightarrow{\text{Decision}} w_1$

③ analysis

• if $x \in [a, b]$:

$$\frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-\mu)^2}{2\sigma^2}} > \frac{p(w_2)}{p(w_1)} \times \frac{1}{b-a} \rightarrow e^{-\frac{(x-\mu)^2}{2\sigma^2}} > \frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}$$

$$\xrightarrow{\ln} -\frac{(x-\mu)^2}{2\sigma^2} > \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right)$$

$$\Rightarrow (x-\mu)^2 < -2\sigma^2 \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right)$$

$$\Rightarrow -\sqrt{-2\sigma^2 \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right)} < x-\mu < \sqrt{-2\sigma^2 \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right)}$$

$$\Rightarrow \underbrace{\mu - \sigma \sqrt{-2 \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right)}}_A < x < \underbrace{\mu + \sigma \sqrt{-2 \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right)}}_B$$

حالت ① اگر A و B حقیقی نباشند، باز R_1 و R_2 را میتوان بصورت زیر تعریف کرد:

$$R_1 = (-\infty, a) \cup (b, +\infty) \quad \text{و} \quad R_2 = (a, b)$$

$$\begin{aligned} P(\text{error}) &= P(w_1) \times \int_{R_2} p(x|w_1) dx + P(w_2) \times \int_{R_1} p(x|w_2) dx = \dots \\ &= P(w_1) \times \int_{R_2} p(x|w_1) dx = P(w_1) \int_a^b p(x|w_1) dx \leq \int_a^b p(x|w_1) dx \end{aligned}$$

حالت ② اگر A و B حقیقی باشند $\Leftrightarrow -2 \ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right) > 0$

$$\ln\left(\frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a}\right) < 0 \Rightarrow \frac{p(w_2)}{p(w_1)} \times \frac{\sqrt{2\pi}\sigma}{b-a} < e^0 = 1$$

$$\frac{P(w_2)}{P(w_1)} \times \frac{1}{b-a} < \frac{1}{\sqrt{2\pi}\sigma} \implies \frac{P(w_2)}{P(w_1)} \times \frac{1}{b-a} < \frac{1}{\sqrt{2\pi}\sigma} \left(e^{-\frac{(\mu-\mu)^2}{2\sigma^2}} \right)$$

$n=\mu$

چون این نامعادله برای $x \in (A, B)$ است. تمام نقاط این بازه N کلاس w_1 متعلق هستند. در این صورت بازه R_1 و R_2 را می‌توان تعریف کرد:

$$R_1 = (-\infty, a) \cup (b, +\infty) \cup (A, B) \rightarrow \text{semi minus}$$

$$R_2 = (a, b) - (A, B) = (a, b) \setminus (A, B)$$

$$P(\text{error}) = P(w_1) \int_{R_2} p(x|w_1) dx + P(w_2) \int_{R_1} p(x|w_2) dx = P(w_1) \int_{(a,b) \setminus (A,B)} p(x|w_1) dx + P(w_2) \int_{(a,b) \cap (A,B)} p(x|w_2) dx$$

$\xrightarrow{\text{چون } p(x|w_2) = 0 \text{ if } x \notin (a,b)}$

حال برای هر نقطه x به طور کلی $x \in (A, B)$:

$$P(w_1)P(x|w_1) > P(w_2)P(x|w_2)$$

$$\xrightarrow{\text{بسیار}} P(w_1) \int_{(a,b) \cap (A,B)} p(x|w_1) dx > P(w_2) \int_{(a,b) \cap (A,B)} p(x|w_2) dx$$

$$\implies P(\text{error}) \leq P(w_1) \int_{(a,b) \setminus (A,B)} p(x|w_1) dx + P(w_1) \int_{(a,b) \cap (A,B)} p(x|w_1) dx =$$

$$P(w_1) \int_a^b p(x|w_1) dx \leq \int_a^b p(x|w_1) dx$$

برای هر دو حالت ① و ②، upper bound خط برابر شد با:

$$P(\text{error}) \leq \int_a^b p(x|w_1) dx$$

ادامی سوال 3 طبق صورت سؤال $P(x|w_i)$ گوسی است یا نه:

$$\text{upper bound} = \int_a^b P(x|w_i) dx = \int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}z^2} dz =$$

upper bound

normalize

$$= \int_{-\infty}^{\frac{b-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}z^2} dz - \int_{-\infty}^{\frac{a-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}z^2} dz = G\left(\frac{b-\mu}{\sigma}\right) - G\left(\frac{a-\mu}{\sigma}\right)$$

فرمول حرکت از distance ها به صورت زیر است (برای دو کلاس):

Euclidean

$$\text{distance} \rightarrow \sqrt{\sum_{i=1}^d (R_i - B_i)^2}$$

$$\text{Manhattan distance} \rightarrow \sum_{i=1}^d |R_i - B_i|$$

$$\text{Chebyshev distance} \rightarrow \max_{i \in \{1, 2, \dots, d\}} |R_i - B_i|$$

مقدار centroid برای کلاس های Blue و Red به صورت زیر است:

$$\vec{\mu}_{\text{Blue}} = \frac{1}{4} \left(\begin{bmatrix} 2 \\ 5 \end{bmatrix} + \begin{bmatrix} 2 \\ -1 \end{bmatrix} + \begin{bmatrix} 4 \\ 1 \end{bmatrix} + \begin{bmatrix} 8 \\ 4 \end{bmatrix} \right) = \begin{bmatrix} 4 \\ 2.25 \end{bmatrix}$$

$$\vec{\mu}_{\text{Red}} = \frac{1}{4} \left(\begin{bmatrix} -3 \\ 9 \end{bmatrix} + \begin{bmatrix} -3 \\ 4 \end{bmatrix} + \begin{bmatrix} -3 \\ -1 \end{bmatrix} + \begin{bmatrix} 1 \\ 4 \end{bmatrix} \right) = \begin{bmatrix} -2 \\ 4 \end{bmatrix}$$

centroid

Nearest - Chebyshev:

$$(2, 2), (4, 2.25): \max\{2, 0.25\} = 2 \text{ class B}$$

$$(2, 2), (-2, 4): \max\{4, 2\} = 4 \text{ class Red} \Rightarrow \text{class B}$$

Nearest centroid - Manhattan distance:

$$(2,2), (4,2.25): 2+0.25=2.25 \text{ class B} \Rightarrow \text{class B}$$

$$(2,2), (-2,4): 4+2=6 \text{ class R}$$

Nearest centroid - euclidean distance.

$$(2,2), (4,2.25): \sqrt{4+0.0625}=2.0155 \text{ class B}$$

$$(2,2), (-2,4): \sqrt{16+4}=4.472 \text{ class R} \Rightarrow \text{class B}$$

Nearest neighbor - chebyshev distance:

$$(2,2), (1,4): \max(1,2)=2 \text{ class R}$$

$$(2,2), (2,5): \max(0,3)=3 \text{ class B}$$

$$(2,2), (4,1): \max(2,1)=2 \text{ class B}$$

فرقی نداره. تصادفی
یک کلاس انتخاب میشه
(فاصله کمینه از هر دو کلاس برابره)

Nearest neighbor - Manhattan distance:

$$(2,2), (1,4): 1+2=3 \text{ class R}$$

$$(2,2), (2,5): 0+3=3 \text{ class B}$$

$$(2,2), (4,1): 2+1=3 \text{ class B}$$

اینجا هم فاصله ها برابر شده
(بزرگ هر دو کلاس) است
به طور تصادفی یک کلاس انتخاب میشه

Nearest neighbor - Euclidean distance:

$$(2,2), (1,4): \sqrt{1+4}=\sqrt{5} \text{ class R}$$

$$(2,2), (2,5): \sqrt{0+9}=3 \text{ class B}$$

$$(2,2), (4,1): \sqrt{4+1}=\sqrt{5} \text{ class B}$$

//

	Nearest neighbor	Nearest centroid
chebyshev	Red or Blue	Blue
Manhattan	Red or Blue	Blue
Euclidean	Red or Blue	Blue

5

$$P(\mu|X) = \frac{P(X|\mu)P(\mu)}{\underbrace{P(X)}_{\text{ثابت}}} \quad K=0$$

$P(X)$ ثابت پس می توانیم آن را در نظر نگیریم. همچنین چون داده ها به صورت i.i.d هستند، می نویسیم:

$$P(\mu|X) = K \prod_{i=1}^N P(x_i|\mu)P(\mu) = K \prod_{i=1}^N \left(\frac{1}{\sqrt{2\pi\Sigma}} \right) e^{-\frac{1}{2}(x_i-\mu)^T \Sigma^{-1}(x_i-\mu)}$$

$$\times \frac{1}{\sqrt{2\pi\Sigma_0}} e^{-\frac{1}{2}(\mu-\mu_0)^T \Sigma_0^{-1}(\mu-\mu_0)} = K' e^{-\frac{1}{2} \left(\sum_{i=1}^N (x_i-\mu)^T \Sigma^{-1}(x_i-\mu) + (\mu-\mu_0)^T \Sigma_0^{-1}(\mu-\mu_0) \right)}$$

$$= K' \exp \left\{ -\frac{1}{2} \left(\sum_{i=1}^N (x_i^T \Sigma^{-1} x_i) - \mu^T \Sigma^{-1} x_i - x_i^T \Sigma^{-1} \mu + \mu^T \Sigma^{-1} \mu \right) + \right. \\ \left. + (\mu^T \Sigma_0^{-1} \mu - \mu_0^T \Sigma_0^{-1} \mu - \mu^T \Sigma_0^{-1} \mu_0 + (\mu_0^T \Sigma_0^{-1} \mu_0)) \right\} = \quad (*) \\ = \left(K'' \exp \left\{ -\frac{1}{2} \mu^T (N \Sigma^{-1} + \Sigma_0^{-1}) \mu + \mu^T \left(\Sigma^{-1} \sum_{i=1}^N x_i + \Sigma_0^{-1} \mu_0 \right) + cte \right\} \right)$$

و داریم:

$$P(\mu|\mu_n) = K'' \exp \left\{ -\frac{1}{2} (\mu - \mu_n)^T \Sigma_n^{-1} (\mu - \mu_n) \right\} =$$

$$= K'' \exp \left\{ -\frac{1}{2} (\mu^T \Sigma_n^{-1} \mu - \mu^T \Sigma_n^{-1} \mu_n - \mu_n^T \Sigma_n^{-1} \mu + \underbrace{\mu_n^T \Sigma_n^{-1} \mu_n}_{cte}) \right\} \\ = \left(K'' \exp \left\{ -\frac{1}{2} \mu^T \Sigma_n^{-1} \mu + \mu^T \Sigma_n^{-1} \mu_n + cte \right\} \right) \quad (*)$$

$$(*) = (*) \Rightarrow \Sigma_n^{-1} = N \Sigma^{-1} + \Sigma_0^{-1} \quad (a+b)^T = b^T (a^T + b^T) \bar{a}^T \quad \Sigma_n = \Sigma_0 \left(\frac{1}{N} \Sigma + \Sigma_0 \right)^{-1} \frac{1}{N} \Sigma$$

$$\mu^T \left(\Sigma^{-1} \sum_{i=1}^N x_i + \Sigma_0^{-1} \mu_0 \right) = \mu^T \Sigma_n^{-1} \mu_n \Rightarrow \mu_n = \Sigma_n \left(\Sigma^{-1} \sum_{i=1}^N x_i + \Sigma_0^{-1} \mu_0 \right)$$

$$\Rightarrow \mu_n = \Sigma_0 \left(\frac{1}{N} \Sigma + \Sigma_0 \right)^{-1} \frac{1}{N} \Sigma \left(\Sigma^{-1} \sum_{i=1}^N x_i + \Sigma_0^{-1} \mu_0 \right)$$