

810100355

تمرین ML - سی 2

لنار رستمی

1-

الف) روش هسٹوگرام - روش ساده‌ای برای بخش‌بندی فضا به تعدادی سلول هم اندازه می‌باشد و سپس محاسبه هسٹوگرام می‌باشد. روش هسٹوگرام برای حجم دیتا مخصوصاً زمانی که داده تک بعدی باشد، بسیار مناسب است.

ب)

مزایای روش parzen:

- می‌توان از آن برای داده‌ها از هر توزیعی استفاده کرد.
- درکتوری، می‌توان نشان داد که با رفتن تعداد نمونه‌ها به سمت بی‌نهایت، همگرا می‌شود.
- معایب روش parzen:
- ممکن است به تعداد زیادی داده نیاز داشته باشد تا تخمین دقیق‌تری انجام دهد.
- تعداد داده‌های train در عمل محدود است و انتخاب اندازه‌ی پنجره‌ی مناسب (h) دشوار است.
- پنج‌چیزی محاسبه‌ی بالا (برای classify کردن یک نقطه، باید یک تابع را محاسبه کنیم که احتمالاً به کل نمونه‌ها بستگی دارد).
- انتخاب سایز پنجره (h) کار ساده‌ای نیست.

مزایای روش KNN:

- می‌توان از آن برای داده‌ها از هر نوع توزیعی استفاده کرد (مثل parzen).
- بسیار ساده و قدرتمند است.
- اگر اندازه‌ی سمپل به قدر کافی بزرگ باشد، classification را به خوبی انجام می‌دهد.
- معایب روش KNN:
- انتخاب بهترین مقدار K ممکن است دشوار باشد.
- همانند parzen، پنج‌چیزی محاسبه‌ی بالا دارد اما قابل بهبود است.
- برای دقت بالا، به تعداد نمونه‌های زیادی نیاز دارد (مثل parzen).
- هیچ وقت این مشکل را نمی‌توان به طرف کرد مگر با فرض کردن توزیع پارامتریک.

ادامه صفحه بعد:

به طور کلی، روش parzen زمانی خوب جواب می‌دهد که k عدد بزرگی باشد، بنابراین در جاهایی که داده کمی داریم، پاسخ خوبی نمی‌دهد.


بهتر است در مواردی که داده‌ها متراکم هستند از parzen و در مواردی که داده‌ها sparse هستند از knn استفاده کنیم.

زمانی که pdf کینواخت باشد، هر دو به خوبی کار می‌کنند.


زمانی که احتمال posterior دقیقاً یکنواخت باشد، ML و MAP یکسان عمل می‌کنند. (۲)

۲- با استفاده از کد ضمیمه شده (p2) knn را با $k=1$ اجرا کردم که نتایج بدست آمده برای هر بخش به صورت زیر است:


(الف)




(ب)



(ج)





$$P(w_i) = \frac{1}{c} \quad , \quad P(x|w_i) = \begin{cases} 1 & 0 \leq x \leq \frac{cr}{c-1} \\ 1 & i \leq x \leq i+1 - \frac{cr}{c-1} \\ 0 & \text{otherwise} \end{cases} \quad -3$$

$$P(x) = \sum_{i=1}^c P(x|w_i)P(w_i) = \begin{cases} 1 & 0 \leq x \leq \frac{cr}{c-1} \\ \frac{1}{c} & i \leq x \leq (i+1) - \frac{cr}{c-1} \quad (*) \\ 0 & \text{otherwise} \end{cases}$$

$$(*) \rightarrow 0 \leq \frac{cr}{c-1} \leq 1 \rightarrow 0 \leq r \leq \frac{c-1}{c}$$

The Bayes error:

$$\begin{aligned} \textcircled{1} P^* = P(e) &= \int P(e|x) p(x) dx = P(e|0)P(0) + P(e|\text{not } 0)P(\text{not } 0) = \\ &= \frac{c-1}{c} \frac{cr}{c-1} + 0 \left(1 - \frac{cr}{c-1}\right) = r \end{aligned}$$

The nearest neighbor error rate:

$$\begin{aligned} \textcircled{2} P &= \int \left[1 - \sum_{i=1}^c P^2(w_i|x) \right] p(x) dx = \int_0^{cr/(c-1)} \left(1 - \frac{c(\frac{1}{c})^2}{p^2(x)} \right) p(x) dx + \\ &\sum_{j=1}^c \int_j^{j+1 - \frac{cr}{c-1}} [1 - 1] p(x) dx = \int_0^{\frac{cr}{c-1}} \left(1 - \frac{1}{p^2(x)} \right) p(x) dx = \\ &\int_0^{\frac{cr}{c-1}} \left(1 - \frac{1}{c} \right) dx = \left(1 - \frac{1}{c} \right) \frac{cr}{c-1} = r \end{aligned}$$

$$\textcircled{1}, \textcircled{2} \Rightarrow P^* = P = r$$

$$P(x_1) = \begin{cases} \frac{1}{\theta_1} e^{-\theta_1 x_1} & ; x_1 > 0 \\ 0 & ; \text{otherwise} \end{cases}$$

$$P(x_2) = U(0, \theta_2) = \begin{cases} \frac{1}{\theta_2} & ; 0 \leq x_2 \leq \theta_2 \\ 0 & ; \text{otherwise} \end{cases}$$

$$L(\theta | x, y) = L(\theta | x, y) = P(x, y | \theta)$$

log

$$\log L(\theta | x, y) = \log P(x, y | \theta) = \sum_{i=1}^n \log P(x_i, y_i | \theta) =$$

$$= \sum_{i=1}^n \log P_{y_i}(x_i | \theta, y_i)$$

$$Q(\theta | \theta^0) = E_{y|x, \theta^0} [\log L(\theta | x, y)] = \int_{-\infty}^{+\infty} \log(P(x_i | \theta)) P(y | x, \theta) dy$$

$$= \int_{-\infty}^{+\infty} \log(P(x_1 | \theta)) P(y | x, \theta^0) + \log(P(x_2 | \theta)) P(y | x, \theta^0) +$$

$$\log(P(x_3 | \theta)) P(y | x, \theta^0) dy = \log(P(x_1 | \theta)) \int_{-\infty}^{+\infty} P(y | x, \theta^0) dy +$$

$$\log P(x_2 | \theta) \int_{-\infty}^{+\infty} P(y | x, \theta^0) dy + \int_{-\infty}^{+\infty} \log(P(x_3 | \theta)) P(y | x, \theta^0) dy$$

$$= \log P(x^{(1)} | \theta) + \log P(x^{(2)} | \theta) + \int_{-\infty}^{+\infty} (\log P(x_1^{(3)} | \theta) + \log P(x_2^{(3)} | \theta)) P(x^{(3)} | x, \theta^0) dx$$

$$\Rightarrow P(x^{(3)} | x, \theta^0) = \frac{P(x^{(3)} | \theta^0)}{\int_{-\infty}^{+\infty} P(x^{(3)} | \theta^0) dx^{(3)}}, \quad \theta^0 = \begin{pmatrix} 2 \\ 4 \end{pmatrix} = \begin{pmatrix} \theta_1^0 \\ \theta_2^0 \end{pmatrix}$$

$$P(x^{(3)} | x, \theta) = \frac{P(x_1^{(3)} | \theta^0) P(x_2^{(3)} | \theta^0)}{\int_{-\infty}^{+\infty} P(x_1^{(3)} | \theta^0) P(x_2^{(3)} | \theta^0) dx_2^{(3)}} = \frac{P(x_1^{(3)} | \theta^0) P(x_2^{(3)} | \theta^0)}{P(x_1^{(3)} | \theta^0) \int_{-\infty}^{+\infty} P(x_2^{(3)} | \theta^0) dx_2^{(3)}}$$

ادامس سؤال 4. قسمت الف.

$$(*) \int_{-\infty}^{+\infty} (\log P(x_1^{(3)}|\theta) + \log P(x_2^{(3)}|\theta)) P(x_2^{(3)}|\theta^0) dx_2^{(3)}$$

$$\textcircled{1} \quad \underline{3 \leq \theta_2 \leq 4} : \int_0^{\theta_2} (\log(\frac{1}{\theta_1} e^{-2\theta_1}) + \log(\frac{1}{\theta_2})) \frac{1}{4} dx_2^{(3)} =$$

$$= \frac{\theta_2}{4} (-\log \theta_1 - 2\theta_1 - \log \theta_2)$$

$$(*) \rightarrow \textcircled{2} \quad \underline{\theta_2 \gg 4} : \int_0^4 (\log(\frac{1}{\theta_1} e^{-2\theta_1}) \log \theta_2) \frac{1}{4} dx_2^{(3)} =$$

$$= -\log \theta_1 - 2\theta_1 - \log \theta_2$$

$$\textcircled{3} \quad \underline{\text{otherwise}} : = 0$$

$$Q(\theta, \theta^0) = \log P(x^{(1)}|\theta) + \log P(x^{(2)}|\theta) + (*)$$

Q(θ, θ⁰) به مقدار می تواند ثابت باشد:

$$\textcircled{1} \rightarrow Q(\theta, \theta^0) = \log(P(x_1^{(1)}|\theta)P(x_2^{(1)}|\theta)) + \log(P(x_1^{(2)}|\theta)P(x_2^{(2)}|\theta))$$

$$+ \frac{\theta_2}{4} (-\log \theta_1 - 2\theta_1 - \log \theta_2) = -\log \theta_1 - \theta_1 - \log \theta_2 - \log \theta_1$$

$$-3\theta_1 - \log \theta_2 + \frac{\theta_2}{4} (-\log \theta_1 - 2\theta_1 - \log \theta_2) =$$

$$-2\log \theta_1 - 2\log \theta_2 - 4\theta_1 + \frac{\theta_2}{4} (-\log \theta_1 - 2\theta_1 - \log \theta_2)$$

ادامی سوال 4، قسم الف

$$\textcircled{2} \rightarrow Q(\theta, \theta^*) = -3 \log \theta_1 - 6\theta_1 - 3 \log \theta_2$$

$$\textcircled{3} \rightarrow Q(\theta, \theta^*) = -2 \log \theta_1 - 2 \log \theta_2 - 3\theta_1$$

$$P(x_1) = \frac{1}{\theta_1} e^{-\theta_1 x_1}$$

ب

$$\int_{-\infty}^{+\infty} P(x_1) dx_1 = 1 \rightarrow \int_{-\infty}^{+\infty} \frac{1}{\theta_1} e^{-\theta_1 x_1} dx_1 = \int_0^{+\infty} \frac{1}{\theta_1} e^{-\theta_1 x_1} dx_1$$

$$= \frac{1}{\theta_1} \left[-\frac{1}{\theta_1} e^{-\theta_1 x_1} \right]_0^{+\infty} = \frac{1}{\theta_1} \left[0 + \frac{1}{\theta_1} \right] = 1 \rightarrow \frac{1}{(\theta_1)^2} = 1$$

همواره $\theta_1 = 1$ ← $(3 \leq \theta_2 \leq 4)$

حالت ①

از قسم الف
بدست آوردم

$$\rightarrow Q(\theta, \theta^*) = -2 \log \theta_2 - 4 - \frac{\theta_2}{2} - \frac{\theta_2}{4} \log \theta_2$$

به ازای $\theta_2 = 3$ ، $Q(\theta, \theta^*)$ ماکسیمم می شود.

$$\theta_2 = 3 \rightarrow = -2 \log(3) - 4 - \frac{3}{2} - \frac{3}{4} \log(3) = -6.81$$

0.477

حالت ②
($\theta_2 \geq 4$)

$$\rightarrow Q(\theta, \theta^*) = -3 \log \theta_1 - 6\theta_1 - 3 \log \theta_2$$

به ازای $\theta_2 = 4$ ، $Q(\theta, \theta^*)$ در این حالت ماکسیمم می شود.

$$\theta_2 = 4 \rightarrow = -3 \times 0 - 6 - 3 \log 4 = -12$$


حالت ① < حالت ② ← مقدار جدید برای θ ها

$$\left. \begin{array}{l} \theta_2 = 3 \\ \theta_1 = 1 \end{array} \right\}$$

(1)
c


$$P(X_1) = \begin{cases} \frac{1}{\theta_1} e^{-\theta_1 x_1} & ; x > 0 \\ 0 & ; \text{otherwise} \end{cases}$$

$$\xrightarrow{\theta_1=1} P(X_1) = \begin{cases} e^{-x_1} & ; x > 0 \\ 0 & ; \text{otherwise} \end{cases}$$



$$P(X_2) = \begin{cases} \frac{1}{\theta_2} & ; 0 < x_2 < \theta_2 \\ 0 & ; \text{otherwise} \end{cases}$$

$$\xrightarrow{\theta_2=3} P(X_2) = \begin{cases} \frac{1}{3} & ; 0 < x < 3 \\ 0 & ; \text{otherwise} \end{cases}$$



1. $f(x_k; \theta) = \theta \exp(-\theta x_k) ; x_k \geq 0, \theta > 0$

$$l(\theta|x) = \sum_{i=1}^n \ln(P(x_k|\theta)) \rightarrow \frac{\partial}{\partial \theta} l(\theta|x) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln P(x_k|\theta)$$

$$\ln P(x_k|\theta) = \ln \theta - \theta x_k \rightarrow \frac{\partial}{\partial \theta} \ln P(x_k|\theta) = \frac{1}{\theta} - x_k$$

$$\Rightarrow \frac{\partial}{\partial \theta} l(\theta|x) = \sum_{i=1}^n \frac{1}{\hat{\theta}} - x_k = 0 \Rightarrow \frac{n}{\hat{\theta}} - \sum_{i=1}^n x_k = 0$$

$$\Rightarrow \hat{\theta} = \frac{n}{\sum_{i=1}^n x_k} \Rightarrow \hat{\theta} = \frac{1}{\bar{x}}$$

2. $f(x_k; \theta) = \frac{x_k}{\theta^2} \exp(-\frac{x_k^2}{2\theta^2}) ; x_k \geq 0, \theta > 0$

$$\ln P(x_k|\theta) = \ln x_k - 2 \ln \theta - \frac{x_k^2}{2\theta^2}$$

$$\frac{\partial}{\partial \theta} \ln P(x_k|\theta) = -\frac{2}{\theta} + \frac{x_k^2}{\theta^3} \Rightarrow \frac{\partial}{\partial \theta} \ln(\theta|x) = \sum_{k=1}^n \frac{x_k^2}{\hat{\theta}^3} - \frac{2}{\hat{\theta}} = 0$$

$$\frac{\sum_{k=1}^n x_k^2}{\hat{\theta}^3} = \frac{2n}{\hat{\theta}} \Rightarrow \hat{\theta} = \sqrt{\frac{\sum_{k=1}^n x_k^2}{2n}}$$

3. $f(x_k; \theta) = \sqrt{\theta} x_k^{\sqrt{\theta}-1} ; 0 \leq x_k \leq 1, \theta > 0$

$$\ln P(x_k|\theta) = \frac{1}{2} \ln \theta + \sqrt{\theta}-1 \ln x_k \Rightarrow \frac{\partial}{\partial \theta} \ln P(x_k|\theta) = \frac{1}{2\theta} +$$

$$\frac{1}{2\sqrt{\theta}-1} \ln(x_k) \quad \frac{\partial}{\partial \theta} \ln \theta(x) = \sum_{k=1}^n \frac{1}{2\theta} + \frac{1}{2\sqrt{\theta}-1} \ln(x_k) = 0$$

$$-\frac{n}{\hat{\theta}} = \frac{\sum_{k=1}^n \ln x_k}{\sqrt{\hat{\theta}}-1} \rightarrow \frac{\sqrt{-\hat{\theta}}-1}{\hat{\theta}} = \frac{\sum_{k=1}^n \ln x_k}{n} \rightarrow \frac{\theta-1}{\theta^2} = \alpha^2$$

Subject: _____ Date: _____

Sa Su Mo Tu We Th Fr


ادامه سوال 5، قسمت 3

$$\alpha^2 \theta^2 = \theta - 1 \Rightarrow \alpha^2 \theta^2 - \theta + 1 = 0$$


$$\Rightarrow \theta = \frac{1 \pm \sqrt{1 - 4\alpha^2}}{2\alpha^2}$$

-۶

الف) با بزرگ شدن تعداد binها و در نتیجه‌ی آن کوچک شدن bin width نمودار هیستوگرام (تخمین تابع چگالی) spiky تر می‌شود. اما زمانی که تعداد binها کم است (یعنی زمانی که bin width بزرگ است)، نمودار smoothتر می‌باشد چرا که averaging بزرگی روی تعداد زیادی از داده‌ها داریم انجام می‌دهیم.



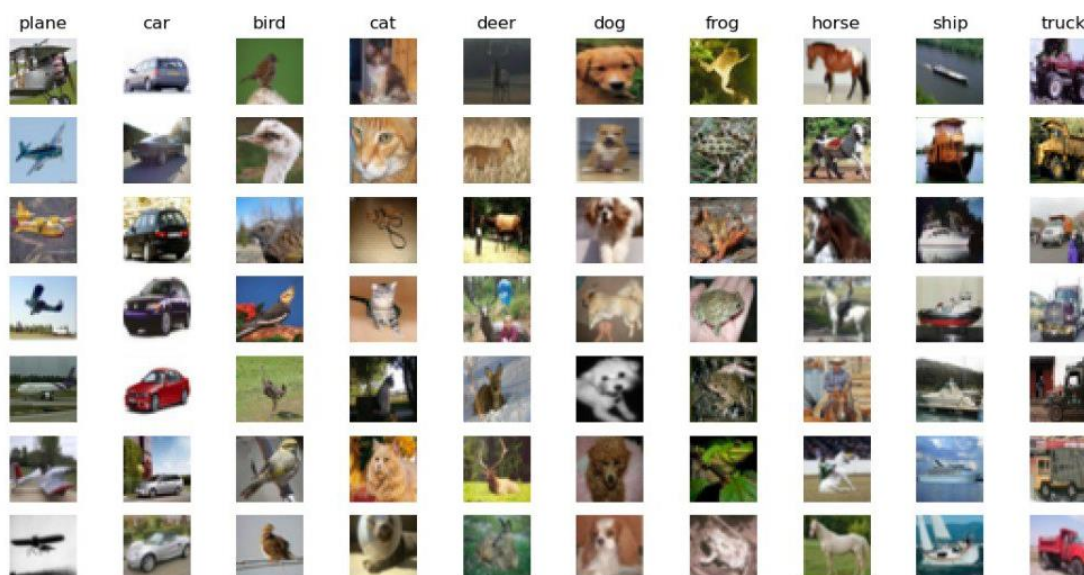
(ب)



یکی از مشکلات روش هیستوگرام برای تخمین چگالی این است که انتخاب سایز bin های متفاوت و location متفاوت برای bin ها می تواند منجر به representation های متفاوتی از داده شود که ویژگی های متفاوتی دارند. یکی از دلایل تفاوت در تخمین چگالی های دو شکل بالا این است که ارتفاع bin اغلب نشان دهنده چگالی داده های اطراف آن bin نمی باشد بلکه نشان دهنده این است که داده ها در چه bin های قرار می گیرند و در واقع ارتفاع هر bin به تعداد داده هایی که به آن bin منطبق می شوند بستگی دارد. همچنین دلیل دیگر تفاوت در دو شکل بالا این است که مرز bin ها در این دو شکل با هم متفاوت است.

۸- قسمتهایی که در گزارش نیامده در کد مربوط به سوال که پیوست شده قرار دادم.

(الف)



د) انتظار میرود که فاصله منتهی مقیاس مناسبتری نسبت به فاصله اقلیدسی برای تعیین فاصله‌ی دو تصویر باشد. فاصله‌ی اقلیدسی توجه زیادی به outlierها می کند در حالیکه فاصله منتهی اهمیت یکسانی برای تمام نقاط قائل می شود. به طور مثال فرض کنید که رنگ پس زمینه دو تصویر گربه بسیار متفاوت باشد. طبق معیار فاصله‌ی اقلیدسی اختلاف این دو تصویر مقدار خیلی زیادی پیدا می کند که مطلوب نمی باشد. نتایج حاصل بر اساس معیار f1_score با اجرای knn به ازای مقادیر 3, 7, 15 k به ازای هر کدام از فواصل به شرح زیر است:

weighted f1 where euclidean, k=03 : 0.3191

weighted f1 where manhattan, k=03: 0.3596

weighted f1 where euclidean, k=07: 0.3208

weighted f1 where manhattan, k=07: 0.3702 <-- best result

weighted f1 where euclidean, k=15: 0.3231

weighted f1 where manhattan, k=15: 0.3662

می بینیم که نتایج بدست آمده با پیش بینی ما همخوانی دارد و به ازای هر مقدار k میزان f1_score با فاصله منتهی بیشتر از میزان f1_score با فاصله اقلیدسی است.

همچنین می بینیم که به ازای k=7 طبقه بند بهتر عمل می کند.